

Mémoire de fin d'année

ING 2-APP

Vers des agents conversationnels plus humains: automatiser sans déshumaniser



ISSAD Nassim

M1-BDML 1

Abstract (Résumé en anglais).....	3
I - Présentation de l'entreprise.....	4
II- Analyse du contexte et de la problématique.....	5
A- Croissance et efficacité : concilier ambition et réalité opérationnelle	
B- L'automatisation comme levier stratégique.....	5
C- Vers un ensemble d'agents conversationnels.....	7
III. La conception des agents conversationnels intelligents.....	9
A- L'agent conversationnel pour le recrutement.....	9
B- Un chatbot pour répondre aux questions des élèves lors de la formation.....	12
C- Un agent conversationnel vocal no-code pour optimiser le travail des téléprospecteurs.....	16
IV. Résultats et impact.....	18
V. Conclusion.....	20

Abstract (Résumé en anglais)

This work focuses on how we experimented with some chatbots at Audits Énergies.

Audits Énergies, the company where I work, is a small business that works in energy renegotiation and telemarketing training. The company is growing fast but doesn't have enough people to grow further. So they recruited me to automate some tasks. And I had to automate some conversational tasks.

One of my first tasks was to create a system to schedule job interviews automatically. But this didn't work well. Indeed, many people didn't show up for their interviews.

We learned that automation needs to feel more human. This made us ask: how can we use chatbots to do some tasks automatically but still keep good communication with users?

We built three different chatbots for different jobs:

1- Email Recruitment Bot: This algorithm was created to discuss by email only with candidates and to schedule interviews with them automatically. It understands what they want to say, and even if every scenario is programmed, it sounds very personal.

2- Student Help Chatbot: This bot helps students with their questions about courses. Instead of having a chatbot that only gives answers to students by calling an LLM through its API, this chatbot works on the principle of a RAG. Indeed, we gave it all the course materials so it can answer questions correctly. It uses an LLM (in this case GPT-4) but only talks about things from the courses, not other topics.

3- Phone Sales Bot: We created a conversational agent on the VAPI platform. This bot's aim is to call customers. Then it talks to them, asks questions, and tries to reach the director of the company they're calling, or a person in charge. And if it manages to reach one, it transfers the call to a human salesperson to continue the process.

The results were different for each conversational agent. Indeed, the email bot worked very well. It was as good as humans at getting people to come to interviews.

The "student bot" was helpful because it works 24 hours a day, and it allows students to get answers to all their questions about the course. But we can maybe do better. For example, we could fine-tune the bot to give it a more human-like personality. In the future, with the evolution of Eleven Labs, we could maybe create a feature that lets the student ask questions orally and get oral answers from the bot.

And finally, the phone bot that used VAPI technology had problems because current technology for voice calls isn't good enough yet. And by using it, we risk losing too many clients.

This work shows that conversational agents work best when they combine smart AI with clear business rules.

If we try to automate everything, people don't like it. But if we design the system carefully, it can work almost as well as humans.

The main lesson is that chatbots should help humans, not replace them completely. This is especially important for sales and customer relationships where people need to trust you.

This work helps us understand how companies can use AI chatbots to work more efficiently while still keeping the human touch that customers want.

I - Présentation de l'entreprise

Nous vivons aujourd'hui dans un monde où le marché de l'énergie s'est libéralisé. En effet, jusqu'à la fin des années 1990 par exemple, le marché de l'électricité était un monopole public.

Cela signifie qu'EDF était quasiment le seul fournisseur d'électricité autorisé à vendre aux particuliers et aux entreprises.

Cependant, à partir de 1999, sous l'impulsion des directives européennes, le marché de l'énergie a été progressivement libéralisé.

De nouveaux fournisseurs ont pu entrer sur le marché, les clients ont eu le droit de choisir leurs propres fournisseurs, et les fournisseurs qui avaient un monopole absolu (comme EDF avec l'électricité) ont dû ouvrir l'accès de leur réseau à leurs concurrents. C'est dans ce contexte particulier qu'en 2022, Valentin Guemache et Mehdi Rousselle, décident de fonder leur entreprise.

Face à la libéralisation du marché, beaucoup d'entreprises manquent d'expertise pour identifier les meilleures offres. Le but des deux fondateurs avec Audits Énergies, est donc de rendre l'énergie plus accessible pour les entreprises, moins coûteuse et à fortiori de les aider à renégocier leurs contrats d'énergie.

C'est de cette manière qu'ils établissent leurs locaux à Noisy-Le-Grand, puis commencent à recruter. Un service RH est rapidement constitué, et plusieurs téléprospecteurs sont embauchés dans le but de démarcher les entreprises et de leur proposer un accompagnement dans la renégociation de leurs contrats d'énergie.

Seulement, ces téléprospecteurs, il faut les former au préalable. Certes, s'ils ont été recrutés, c'est qu'ils s'expriment plutôt bien, mais cela ne suffit pas : il est nécessaire de leur transmettre les fondamentaux de la communication commerciale, les enjeux spécifiques liés au secteur de l'énergie, ainsi que les bonnes pratiques à adopter sur le terrain.

Un bon téléprospecteur, c'est avant tout quelqu'un capable d'adapter son discours au profil de son interlocuteur, de faire preuve de pédagogie, et de respecter un refus explicite sans insister.

Mais c'est aussi et surtout quelqu'un qui maîtrise parfaitement son sujet, qui connaît les évolutions réglementaires du secteur de l'énergie, et qui est ainsi en mesure d'être force de proposition et de convaincre efficacement son prospect.

C'est dans ce contexte précis que les fondateurs d'Audits Énergies font alors le choix d'élargir leur champ d'activité.

L'entreprise, initialement positionnée comme cabinet de courtage en énergie, devient également un centre de formation dédié aux téléprospecteurs.

Elle forme désormais non seulement ses propres téléprospecteurs, mais également des téléprospecteurs destinés à intégrer d'autres entreprises de démarchage partenaires, renforçant ainsi son rôle dans l'écosystème commercial B2B.

II- Analyse du contexte et de la problématique

A- Croissance et efficacité : concilier ambition et réalité opérationnelle

Audits Énergies est une jeune entreprise en forte croissance, positionnée sur deux marchés complémentaires : celui de l'énergie, en tant que cabinet de courtage aidant les entreprises à renégocier leurs contrats, et celui de la formation professionnelle, en tant que centre de formation de téléprospecteurs.

Dans ces deux secteurs, une entreprise performante sera une entreprise capable :

- de s'adapter aux besoins de chaque client
- de leur apporter une réelle valeur ajoutée
- d'avoir une approche agile vis-à-vis des changements du marché.

C'est donc dans ce contexte exigeant que, dès le départ, l'entreprise a dû concilier ses objectifs de croissance avec une réalité concrète : comment se développer avec une petite équipe ?

Car dans un marché aussi compétitif, lorsqu'on cherche à être vraiment efficace et à se concentrer sur ce qui nous fera sortir du lot, certaines tâches peuvent vite devenir encombrantes, très chronophages, et finir par freiner la progression de l'entreprise.

B- L'automatisation comme levier stratégique

Pour répondre à ces contraintes, la direction a fait le choix stratégique de s'orienter vers l'automatisation de ses processus. L'objectif n'est pas de remplacer les collaborateurs, mais de les recentrer sur des missions à plus forte valeur ajoutée.

Et c'est justement pour contribuer à l'automatisation des processus de l'entreprise que j'ai été recruté.

Pourtant, dès mon arrivée, une première expérimentation a rapidement révélé les limites d'une automatisation sans interaction humaine.

En effet, l'une de mes premières missions a consisté à concevoir un système d'automatisation via la plateforme Make. À chaque nouveau candidat renseigné dans la base de données, un email lui était automatiquement envoyé, avec dedans un lien lui permettant de choisir un créneau d'entretien directement dans Google Calendar.




Figure 1 - Le schéma ci-dessus illustre le workflow complet : le processus démarre dès qu'un nouveau candidat est ajouté dans la base de données Notion. Un email est alors généré et envoyé automatiquement, contenant le lien de prise de rendez-vous sur google calendar. Une fois le créneau sélectionné par le candidat, l'information est automatiquement transférée dans Notion.

En apparence simple, rapide et efficace, ce processus s'est pourtant révélé complètement contre-productif. En effet, de nombreux candidats prenaient un rendez-vous sans jamais s'y présenter.

Nous avons donc dans un premier temps émis l'hypothèse selon laquelle l'absence totale d'échange humain nuisait à l'engagement des candidats.

Puis, pour tester si cette hypothèse était juste, nous avons mis en place une nouvelle approche : la prise de rendez-vous était cette fois assurée manuellement par une chargée de recrutement, qui échangeait par email avec chaque candidat pour fixer un créneau personnalisé. Les résultats ont été sans appel : le taux de présence aux entretiens approchait les 100 %.

Cette expérience a fait émerger une conviction forte : **automatiser ne suffit pas.**

Il faut créer de l'engagement à travers des échanges contextualisés, proches de l'interaction humaine.

C'est ainsi qu'est née l'idée de développer un agent conversationnel, capable de simuler une véritable discussion par mail avec le candidat. L'utilisation de l'IA n'a pas vocation à "répondre librement" au candidat, mais à analyser le contenu des messages, à en extraire des intentions claires (acceptation, refus, proposition d'un autre créneau), et à appliquer une logique métier définie pour proposer une réponse cohérente. Ce système hybride allie une compréhension intelligente (avec l'IA) et un pilotage rigoureux (avec des règles codées).

Développer un agent conversationnel pensé spécialement pour échanger avec les candidats lors d'un recrutement, s'est vite révélée être une solution pertinente.

L'entreprise a donc souhaité étendre ce principe à d'autres dimensions clés de son activité, en intégrant deux autres agents conversationnels.

C- Vers un ensemble d'agents conversationnels

- *Une formation assistée par IA: le deuxième agent*

En plus d'être un centre de formation, Audits Énergies dispose d'un programme de formation en ligne visant à enseigner les fondamentaux de la relation client à distance.

Parfois, les élèves ont énormément d'interrogations, et c'est tout à fait normal.

Cependant, un professeur lui, n'a pas forcément le temps de répondre de manière détaillée à absolument toutes les questions de tous ses élèves. Et même si la volonté y est, ce n'est pas une machine...

Dans ce cadre, l'intégration d'un agent conversationnel pédagogique s'est rapidement imposée comme une solution pertinente pour accompagner les apprenants et répondre à leurs interrogations en temps réel.

L'objectif n'est pas de proposer un assistant générique basé sur un LLM classique, mais bien un agent capable de fournir des réponses précises, uniquement fondées sur le contenu du cours dispensé.

L'enjeu ici est donc, à travers cet agent conversationnel, de reproduire le comportement d'un formateur humain, qui sera disponible, en apportant des réponses ciblées, contextualisées, et pédagogiques, tout en évitant les dérives potentielles d'une IA non encadrée.

- *Une prospection vocale plus efficace avec l'IA: le troisième agent*

De manière similaire, le processus de prospection téléphonique a été lui aussi repensé.

L'idée n'est pas de remplacer le téléprospecteur, mais de lui permettre de se concentrer sur les échanges à forte valeur ajoutée.

C'est dans cette optique que l'entreprise a décidé de mettre en place un agent conversationnel vocal, chargé de passer les appels en amont, de poser les premières questions, et d'identifier automatiquement les interlocuteurs qualifiés.

Dès qu'un profil pertinent est détecté (par exemple, un gérant d'entreprise), l'appel est immédiatement transféré à un téléprospecteur humain.

Une automatisation pareille permettrait de gagner du temps pour qualifier les prospects, tout en préservant l'aspect humain de la relation commerciale.

C'est précisément cette tension entre automatisation et interaction humaine que ce mémoire se propose d'analyser.

À travers ce mémoire, il sera donc question d'explorer la problématique suivante:

Comment mettre en place des agents conversationnels capables d'automatiser certaines tâches sans pour autant nuire à la qualité des échanges avec les utilisateurs ?

L'objectif de ce mémoire est d'explorer comment concevoir un ensemble d'agents conversationnels basés sur l'IA, capables d'automatiser des processus clés (tels que le recrutement, la formation ou la prospection) tout en maintenant une interaction fluide, humaine et contextualisée.

Et, bien que mes missions en entreprise aient été variées, ce mémoire se concentre spécifiquement sur ce thème, car il incarne pleinement les enjeux actuels de transformation digitale au sein de mon entreprise et au sein de notre société de manière plus générale.

Pour répondre à cette problématique centrale, plusieurs questions techniques et organisationnelles doivent être abordées. Elles constituent autant de défis concrets que j'ai rencontrés au fil du projet, et qui structurent l'analyse menée dans ce mémoire :

- Comment adapter l'utilisation d'un LLM à un usage métier spécifique, en respectant des règles prédéfinies et des logiques métiers strictes ?

- Comment concevoir un agent vocal capable d'interagir en temps réel, de gérer un échange, puis de transférer intelligemment l'appel à un téléprospecteur humain au moment opportun ?
- Comment garantir la qualité des réponses d'une IA lorsque l'on veut que ses réponses soient précises ?
- Comment structurer des bases de données pour permettre la réalisation de tels agents ?

III. La conception des agents conversationnels intelligents

Les agents conversationnels développés dans le cadre de ce projet reposent tous sur une philosophie commune : confier à l'IA les tâches répétitives ou à faible valeur ajoutée, tout en maintenant des interactions fluides, contextualisées et encadrées, proches de celles que l'on pourrait avoir avec un véritable humain.

Il faudra donc pour y parvenir, développer une architecture rigoureuse.

A- L'agent conversationnel pour le recrutement

Le premier agent conversationnel que j'ai eu à développer est celui qui gère les échanges mails liés au recrutement des futurs employés. Ce fut aussi l'un des plus intéressants à concevoir car il posait un vrai dilemme : comment automatiser totalement un échange, tout en le personnalisant et en s'assurant qu'il respecte les exigences et les règles du processus de recrutement ?

L'idée de départ est simple : lorsqu'un candidat arrive dans la base de données, l'automatisation se déclenche.




Figure 2 – Déclenchement de l'automatisation suite à l'ajout d'un candidat

Il reçoit alors un mail automatique lui proposant un rendez-vous, parmi les prochains rendez-vous "disponibles" dans la base de données.




Figure 3 – Génération automatique de l'email avec proposition de créneau disponible

Mais derrière ce premier message, les échanges peuvent varier.

Certains candidats refusent, certains proposent un autre horaire, certains acceptent, d'autres encore donnent une réponse ambiguë. Il fallait donc un système capable d'analyser automatiquement ces réponses, et de déclencher les bonnes actions, sans jamais faire d'erreur.

C'est pour ça qu'il a été question dans ce projet d'utiliser l'IA à travers des appels API pour analyser les réponses des candidats.

En effet, dans le système que j'ai dû concevoir, l'IA n'écrit pas de réponses libres. Elle n'a pas non plus pour rôle d'improviser ou de discuter. Son rôle est purement NLP (Natural Language Processing) : elle lit la réponse du candidat et essaie d'en déduire son intention.

Est-ce un refus ? Une acceptation ? Une proposition d'un autre créneau ? Ou une réponse floue qui mérite d'être remontée à un humain du service RH ?

De cette manière, le traitement est 100% automatisé.

Et une fois l'intention du candidat détectée, tout le reste est géré de manière rigide et codée sans intervention humaine :

1) Si la personne accepte: Son rendez-vous est enregistré dans la base de données. Une confirmation lui est envoyée immédiatement. Et son statut passe à "entretien".

2) Si la personne propose un autre/nouveau créneau : le système commence par vérifier la disponibilité du créneau :

- Si le créneau est libre, l'ancien créneau est remis en "disponible", puis le nouveau rendez-vous est confirmé par mail. Le statut du candidat passe alors à "entretien", et l'heure de l'entretien est enregistrée dans la base de données comme dans le cas d'une acceptation directe.
- Sinon, un message personnalisé lui est envoyé avec trois nouvelles propositions de rendez-vous.

3) Si la réponse est ambiguë: le message est automatiquement redirigé vers le service RH, sans action supplémentaire, afin qu'ils puissent le traiter.

4) Si la personne refuse (n'est pas disponible): un nouveau mail lui est envoyé avec trois créneaux alternatifs, et le créneau initialement proposé est remis en disponibilité.

Donc pour résumer, dans les cas où la personne refuse le rendez-vous initial ou bien propose un créneau qui n'est pas disponible, le système lui envoie automatiquement un nouveau mail avec trois créneaux alternatifs.

À partir de cette relance (identifiable par la mention « nouvelles propositions » dans l'objet du mail) une nouvelle logique de traitement s'applique aux réponses reçues :

1) Si la personne accepte l'un des créneaux proposés :

Le rendez-vous correspondant est enregistré dans la base de données, les deux autres créneaux sont remis en disponibilité, et une confirmation est envoyée par mail. Le statut du candidat passe alors à "entretien".

2) Si la personne propose un autre créneau :

Le système vérifie sa disponibilité:

- S'il est libre, le rendez-vous est attribué, les trois créneaux initialement proposés sont remis en disponibilité, et un mail de confirmation est envoyé.

- S'il est indisponible, les trois créneaux sont également libérés, et le message du candidat est automatiquement transmis au service RH pour traitement manuel.

3) Si la personne refuse à nouveau ou reste ambiguë:

Le message est redirigé vers le service RH, sans intervention du système, et les trois créneaux précédemment proposés sont remis en disponibilité.

Le fonctionnement de ce système repose donc sur trois composantes clés :

Une base de données des créneaux qui recense l'ensemble des rendez-vous disponibles. Elle est utilisée exclusivement par l'algorithme pour vérifier les disponibilités, attribuer ou libérer des créneaux en fonction des réponses reçues. C'est donc un outil purement technique, pensé pour les traitements automatisés.

Une base des candidats, sous forme d'un tableau Notion que les équipes RH peuvent consulter. On y retrouve les infos essentielles pour chaque profil : nom, statut, rendez-vous en cours, etc.

Un fichier JSON de suivi, qui assure la traçabilité de tous les échanges. Il associe à chaque message un message_id, une date d'envoi, et un identifiant Notion. Ce fichier permet au niveau de l'algorithme:

- d'identifier à quel message chaque réponse fait suite,
- de vérifier si une réponse a déjà été traitée, et d'éviter que les réponses automatiques s'envoient plusieurs fois pour un seul et même mail.

Ce premier agent m'a permis de faire le constat suivant :

Il est possible de conjuguer intelligence et rigueur, IA et règles métier, pour un système 100% autonome.

B- Un chatbot pour répondre aux questions des élèves lors de la formation

Dans le cadre de la formation à distance dispensée par Audits Énergies, nous avons également très tôt ressenti le besoin d'un agent conversationnel pédagogique capable de répondre aux questions des élèves de manière précise, personnalisée, et alignée avec le contenu du cours.

J'ai donc dû, pour cela, mettre en place un chatbot. Seulement je ne pouvais pas simplement me contenter d'un chatbot, ou chaque question posée par un élève serait un appel API, à un LLM comme GPT-4.

Car oui, si les modèles de langage (LLM), sont capables de produire des réponses grammaticalement correctes et cohérentes, ils sont limités lorsqu'il est question de s'inscrire dans un contexte pédagogique spécifique.




Figure 4 – Limites d'un LLM non spécialisé

Autrement dit, ces modèles, bien qu'extrêmement puissants, sont très généralistes. Ils peuvent donc donner des réponses approximatives, voire contradictoires, avec ce qui a été réellement enseigné durant la formation.

L'une des solutions pour pallier ce problème serait donc d'entraîner notre propre LLM. Mais ce processus serait extrêmement coûteux, difficile à maintenir dans le temps et peu compatible avec les délais et les moyens d'une petite structure comme la nôtre.

La solution à notre problème résidait donc dans une approche comme celle du RAG (Retrieval-Augmented Generation).

Ce mécanisme consiste à combiner une base de connaissances spécifique à notre formation avec un LLM existant. Ce LLM va alors raisonner en allant piocher ses réponses dans notre base de connaissances pour produire ses réponses.




Figure 5 – Fonctionnement d'un agent conversationnel basé sur le RAG

Essayons désormais de comprendre cette architecture à travers un prisme un peu plus scientifique.

L'idée est simple : notre système repose sur une architecture articulée autour de trois grandes étapes: l'encodage, la recherche, et la génération.

Déjà, dans un premier temps, les fichiers de cours de la formation au format PDF sont récupérés puis découpés en segments de textes appelés "chunks". Un tel découpage est nécessaire pour rendre le traitement des documents compatible avec les limites des LLM actuels.

Dans notre cas, nous avons arbitrairement choisi que chaque chunk ferait environ 1000 caractères.

Et, pour que chaque chunk reste compréhensible même pris seul, nous avons ajouté un paramètre dit de "chevauchement" de 200 caractères.




Figure 6 - Exemple d'un chevauchement de 16 caractères

Ce chevauchement joue un rôle crucial lors de l'étape suivante : l'encodage.

Chaque chunk est en effet transformé en un vecteur numérique à l'aide d'un encodeur, ici en l'occurrence, nous avons choisi le modèle all-MiniLM-L6-v2 proposé par Hugging Face. Cet encodeur produit ce que l'on appelle un embedding, c'est-à-dire une représentation mathématique du contenu du texte, utilisée pour comparer les idées ou sujets abordés entre différents morceaux.

Cependant, il est important de noter que l'encodage traite chaque chunk de manière indépendante. Il n'a aucune mémoire du chunk précédent ou suivant.

Ainsi, si une phrase est coupée entre deux chunks sans chevauchement, le modèle peut perdre des éléments clés de sens.

Cela peut entraîner une perte de compréhension ou une interprétation erronée du contenu.

C'est précisément pour éviter ce genre de situation que le chevauchement a été mis en place. En répétant une portion du texte précédent dans le chunk suivant, on s'assure que les phrases importantes ou les idées en transition apparaissent au complet dans au moins un chunk.

Cela va permettre plus tard au modèle d'IA d'avoir une vision plus complète et cohérente du contenu, et donc de générer des réponses plus précises et pertinentes.



Figure 7 – Encodage des documents pédagogiques en vecteurs pour l'indexation dans une base FAISS

Les vecteurs générés sont ensuite stockés dans une base de données vectorielle FAISS. Cette base permet d'organiser tous les embeddings de manière à les retrouver rapidement. Elle joue un rôle fondamental dans le cœur du système RAG, puisqu'elle assure la récupération efficace des passages les plus pertinents, grâce à une mesure de similarité cosinus.

Car oui, lorsqu'un utilisateur pose une question, celle-ci est également encodée via le même modèle MiniLM, ce qui donne un vecteur de requête.

Ce vecteur est ensuite comparé à tous ceux présents dans la base FAISS. Cette étape permet de sélectionner uniquement les morceaux du cours (les chunks) les plus proches de la question.




Figure 8 – Recherche des chunks les plus pertinents dans la base vectorielle

Les chunks les plus pertinents sont alors injectés dans un prompt sur mesure. Ce prompt est ensuite envoyé à un LLM (GPT-4 d'OpenAI ici en l'occurrence).

Le LLM génère alors une réponse complète, adaptée à la question de l'utilisateur et strictement basée sur le contenu extrait du cours. Le rôle du prompt est ici essentiel : il encadre le comportement de l'agent conversationnel, qui agit comme un formateur bienveillant et clair, tutoie systématiquement l'apprenant, et n'utilise que les documents pédagogiques disponibles.

Enfin, la réponse est transmise à l'utilisateur, et l'ensemble de l'interaction (question, réponse) est enregistrée dans une base de données complémentaire. Cela permet au RAG de pouvoir simuler un suivi pédagogique, en se souvenant des réponses qu'il a déjà données.




Figure 9 – Architecture finale du système RAG mis en place

C- Un agent conversationnel vocal no-code pour optimiser le travail des téléprospecteurs

Dans le prolongement de notre logique d'automatisation, nous avons souhaité expérimenter un agent vocal conversationnel, capable de passer des appels à la place d'un téléprospecteur.

L'idée de départ était simple : configurer un agent vocal capable de gérer toute une discussion avec son interlocuteur. Mais rapidement, nous avons constaté que ce scénario n'était pas optimal.

Alors nous avons pensé à une nouvelle stratégie. En effet, les téléprospecteurs démarchent toute la journée. Mais la majeure partie de leur temps, ils ne la passent pas en train de discuter vraiment avec le prospect de choses sérieuses. Entre les répondeurs, les interlocuteurs absents ou non décisionnaires, ou encore les refus catégoriques dès les premières secondes, le temps passé au téléphone est rarement optimisé.

Plutôt que de chercher à automatiser l'ensemble de la discussion commerciale, nous avons donc choisi de recentrer l'agent vocal sur les premières étapes du processus : initier l'appel, poser quelques questions simples, évaluer si le contact est pertinent... et transférer ensuite l'appel à un humain dès qu'un échange de qualité peut avoir lieu.

C'est ici que la plateforme VAPI entre en jeu. VAPI permet de concevoir des agents vocaux intelligents. Voici les étapes concrètes que nous avons suivies :

Nous avons acquis un numéro de téléphone français via Zadarma, que nous avons ensuite connecté à VAPI. Cela permet à l'agent de passer des appels depuis un numéro commençant par "07", comme n'importe quel téléprospecteur pourrait le faire, ce qui évitera que personne ne décroche.

On a ensuite utilisé pour créer notre agent un LLM. Ce LLM, c'est l'élément qui va permettre à l'agent vocal de comprendre les questions posées en langage naturel et d'y répondre. Ensuite les réponses que le LLM fournit sont interprétées à l'oral par l'une des meilleures voix françaises disponibles aujourd'hui, avec à ElevenLabs.




Figure 10 – Fonctionnement de l'agent vocal conversationnel avec VAPI et ElevenLabs

Nous avons défini un script d'appel précis dans la section System Prompt, structuré comme un guide de conversation. Le premier message est simple et direct :

« Bonjour, c'est Bruno de la société Audits Énergies, pourrais-je parler au gérant s'il vous plaît ? »

L'agent suit ensuite un scénario détaillé : il tente de passer le filtre du ou de la dite "réceptionniste", puis cherche à savoir si l'appel mérite d'être transféré à un humain.

Pour répondre aux questions précises que pourrait poser un prospect, nous avons intégré des documents internes dans la mémoire de l'agent. Car oui, VAPI possède un RAG intégré.

Ainsi, l'agent n'inventera rien, il s'appuiera seulement sur les données contenues dans les documents que nous lui avons fourni pour formuler ses réponses aux prospects.

Si la personne refuse ou est réfractaire, l'agent doit mettre fin à l'appel.

Et lorsque l'agent détecte que la personne au bout du fil est le bon interlocuteur (par exemple, un gérant intéressé), il active un outil intégré nommé `transfer_call_tool`. Ce dernier redirige immédiatement l'appel vers le véritable téléprospecteur, prêt à prendre le relais.



Figure 11 – Architecture de VAPI: prompt, RAG, et transfert automatisé vers un téléprospecteur humain

Cette expérimentation marque une nouvelle étape dans notre démarche d'automatisation. Grâce à VAPI, nous avons pu configurer un agent vocal fonctionnel qui agit de manière interactive avec les prospects. Ce dispositif constitue donc une solution intelligente capable de soulager les équipes tout en préservant la qualité du contact commercial.

La suite du mémoire reviendra sur les premiers retours observés, les limites rencontrées, ainsi que les pistes d'amélioration envisagées pour aller plus loin dans l'intégration des processus d'Audits Énergies.

IV. Résultats et impact

En testant ces trois agents conversationnels, nous avons pu vraiment comprendre ce que l'IA peut apporter en entreprise, mais aussi là où elle a ses limites.

1. Un agent performant pour le recrutement

Le premier agent conversationnel, dédié à la gestion automatique des prises de rendez-vous avec les candidats, a sans doute été l'agent le plus abouti. En reproduisant de manière rigoureuse le comportement et les décisions d'une chargée de recrutement humaine, nous avons pu obtenir avec cet agent un taux de présence aux entretiens très élevé, similaire à celui obtenu lors de la phase manuelle.

Cette réussite repose sur deux principaux facteurs : l'utilisation de l'IA (via un LLM) pour analyser de manière intelligente les mails reçus, ainsi qu'un traitement rigoureux et codifié.

Ce premier cas d'usage montre qu'il est possible de confier à un agent conversationnel des tâches de suivi, de relance et de qualification à condition que celles-ci soient bien encadrées et contextualisées.

2. Un agent pédagogique réussi mais perfectible

Le deuxième agent conversationnel, basé sur une architecture RAG (Retrieval-Augmented Generation), s'est révélé être un véritable atout sur le plan pédagogique dans le cadre de notre formation. En s'appuyant uniquement sur le contenu des cours, il répond de manière précise aux interrogations des apprentis, et ce à n'importe quelle heure de la journée.

Néanmoins, j'ai pu observer plusieurs pistes d'améliorations vis-à-vis de cet agent pédagogique.

En effet, même si les réponses sont adaptées au contenu du cours, elles manquent peut-être de "personnalité", et ce malgré le prompt qui est fourni au LLM. Un fine-tuning pourrait être la solution à ce problème car il permettrait à l'IA de mieux incarner la figure du professeur.

Ensuite, parmi les autres améliorations auxquelles on pourrait penser à l'avenir, il y a l'interaction vocale.

Cette fonctionnalité permettrait à un élève d'échanger à tout moment et de manière orale sur les notions du cours qu'il a envie d'assimiler.

En plus, avec l'arrivée de la version V3 d'ElevenLabs, il est possible de faire du "speech to text" de manière extrêmement réaliste. En effet, cette version intègre des balises de style (appelées tags) qui permettent d'imiter de manière bluffante les variations émotionnelles et naturelles d'un humain.

Cependant, cette version reste coûteuse, elle est encore en phase alpha, et elle n'est pas encore accessible via API, ce qui limite son intégration à court terme. Mais dans les prochains mois, voire années, cela pourrait être une piste d'amélioration et ça pourrait transformer l'expérience d'apprentissage en ligne en la rendant plus humaine et plus immersive.

3. Un agent vocal commercial peu adapté au contexte

Le troisième agent IA, conçu via VAPI et utilisé pour la prospection téléphonique, n'a en revanche quant à lui pas produit les résultats escomptés. Il avait pour objectif de qualifier les prospects en amont des appels et de transférer ensuite les interlocuteurs pertinents à un téléprospecteur humain.

Malheureusement, plusieurs limites ont pu être identifiées.

En effet, les agents IA vocaux actuels ne sont pas assez naturels et pas assez performants. Leur temps de réaction dans une discussion est encore trop grand pour que la discussion soit semblable à celle que l'on pourrait avoir avec un humain, et il leur arrive souvent d'avoir des bugs.

Les clients potentiels sont trop précieux pour être laissés entre les mains d'un agent IA encore imparfait. Des leads de qualité pourraient être perdus à cause de mauvaises interactions.

Face à ce constat, l'entreprise a finalement opté pour une autre solution d'automatisation : l'utilisation de Kavkom. Cette plateforme permet de passer des appels en parallèle à de nombreux contacts, mais dès qu'un prospect décroche, l'appel est automatiquement redirigé vers un téléprospecteur humain. Ainsi, l'automatisation optimise le temps sans compromettre la qualité humaine de la relation commerciale.

V. Conclusion

Ce mémoire s'est attaché à explorer une problématique simple mais essentielle dans un contexte de transformation numérique :

Comment mettre en place des agents conversationnels capables d'automatiser certaines tâches sans pour autant nuire à la qualité des échanges avec les utilisateurs ?

À travers la conception de trois agents distincts (pour le recrutement, la formation, et la prospection), une vérité s'est imposée : l'intelligence artificielle, aussi performante soit-elle, ne remplace pas l'humain.

En particulier à l'oral, où le ton et la finesse des échanges jouent un rôle central dans la perception de la qualité de l'interaction.

Pour autant, ce mémoire a également démontré qu'une IA bien encadrée, bien promptée et bien intégrée peut parfaitement reproduire un échange humain. Elle permet alors de gagner en efficacité sans sacrifier l'expérience utilisateur, à condition de bien définir son périmètre d'action.

En définitive, les agents conversationnels peuvent transformer durablement notre façon de recruter, former ou prospecter. À condition de ne jamais oublier, que chaque interaction, aussi automatisée soit-elle, reste avant tout une interaction avec un humain.

L'enjeu reste donc en fonction de chaque contexte métier, d'adapter son utilisation de l'IA, en fonction de ses performances pour ne pas altérer la qualité de la relation avec l'utilisateur final.

Sur le plan professionnel, les projets évoqués lors de ce mémoire m'ont permis de développer une expertise transversale alliant compétences techniques et compréhension des enjeux business.

Ces missions m'ont également permis de monter en compétence dans plusieurs domaines clés : la conception d'architectures logicielles, la gestion de projet, l'analyse des besoins des utilisateurs ainsi que l'évaluation critique des solutions technologiques réalisées.

